W-1

SQL 검색기

상담사 질문을 정형쿼리 또는 NL2SQL로 바꿔 카드 회원 DB에서 안전하게 답을 찾는 동기 요청 워크플로우

팀 design-agentic-ai

작성일 2026-10-15

무단전재 및 배포 금지

설계 개요

상담사가 기다리는 30초 안에, 허용된 뷰만 읽기 전용으로 조회하는 검색기를 설계함

설계 대상과 범위

설계 대상 W-1 SQL 검색기(질문 → 정형쿼리 또는 NL2SQL → 결과 행 반환)

유저스토리 없음

시작 트리거 동기 요청(호출자가 검색을 요청하고 응답을 기다림) → 단계ID 접두어 S-R

설계 범위 요청 검증, 경로 판단, 계획 판정, SQL 검증, SQL 실행, 응답 반환, Groq LLM 커넥터

제외 범위 답변 문장 작성(호출자 몫), 뷰와 RLS 변경, 화면, 배포

DB 취급 시스템 내부 구성요소(사용자 결정). 외부시스템 연동과 커넥터 목록에서 제외

핵심 결정값

1. 전체 시간 예산 30초, 종료 처리 시간 1초
2. LLM: Groq openai/gpt-oss-120b, 타임아웃 12초, 재시도 0회
3. SQL 검증 실패 시 다시 만들기 1회(반복 구간 L-1)
4. 실행 계정 sql_retriever_user, 허용 뷰 7개, 결과 행 상한 200
5. 필드 표기: 이름(타입, 필수 여부, 설명). 타입은 str, int, bool, date, list, obj

무단전재 및 배포 금지

설계 개요: 처음 보는 분을 위한 용어 풀이

NL2SQL을 처음 접하는 검토자도 이 설계서를 읽을 수 있도록 용어를 한 줄씩 풀이함

용어	한 줄 풀이
NL2SQL	사람의 말(자연어) 질문을 LLM이 SQL로 바꾸는 방식
정형쿼리	자주 묻는 조회를 미리 만들어 검증해 둔 고정 SQL. LLM은 ID만 고름
뷰(View)	원본 테이블에서 필요한 컬럼과 기간만 골라 보여 주는 가상 테이블
행 수준 보안(RLS)	같은 테이블이라도 세션에 지정한 회원의 행만 보이게 하는 DB 규칙
세션 변수	한 트랜잭션 동안만 DB에 알려 주는 값. 여기서는 회원ID, 기준일, 거래 제공 시작일
최악값	한 연동이 가장 오래 걸릴 때의 시간. 타임아웃 × (1 + 재시도 횟수)
남은 시간 예산	단계를 시작하기 전에 앞으로 쓸 수 있는 시간을 다시 재는 값
착지 단계	시간이나 재시도를 다 썼을 때 이어서 가는 안전한 단계

읽는 순서

→ ① 흐름
→ ② 단계
→ ③ 연동
→ ④ 반복
→ ⑤ 합계
→ 커넥터
→ ⑥ 실행 중 시간 관리

무단전재 및 배포 금지

목차

설계 가이드의 작성 순서 ① ~ ⑥에 커넥터 설계와 부록을 더해 구성함

1 흐름

① 단계 도출 및 순서 정의

단계 목록, 흐름 도식, Mermaid

② 단계별 명세

S-R1 ~ S-R6

2 시간

③ 외부시스템 연동 명세

④ 반복 구간 명세

⑤ 워크플로우 명세

⑥ 남은 시간 예산 정책

3 연결과 부록

커넥터 설계

목록, LLM 명세, 프롬프트, 응답 구조

부록

뷰와 정형쿼리, SQL 검증 규칙, 필드 영문명, 오류 응답, 설계 점검표, 설계 가정과 위험 항목

무단전재 및 배포 금지

① 단계 도출 및 순서 정의: 단계 목록과 흐름 유형

입력 워크플로우의 6단계를 그대로 쓰고, 분기 2곳과 반복 1곳을 둠

단계 목록

단계ID	단계명	담당자 유형
S-R1	검색 요청 접수와 검증	규칙기반 코드
S-R2	정형쿼리 또는 NL2SQL 판단	생성형AI + 규칙기반 코드
S-R3	계획 적합성 판정	규칙기반 코드
S-R4	SQL 검증	규칙기반 코드
S-R5	SQL 실행	규칙기반 코드
S-R6	응답 구성과 반환	규칙기반 코드

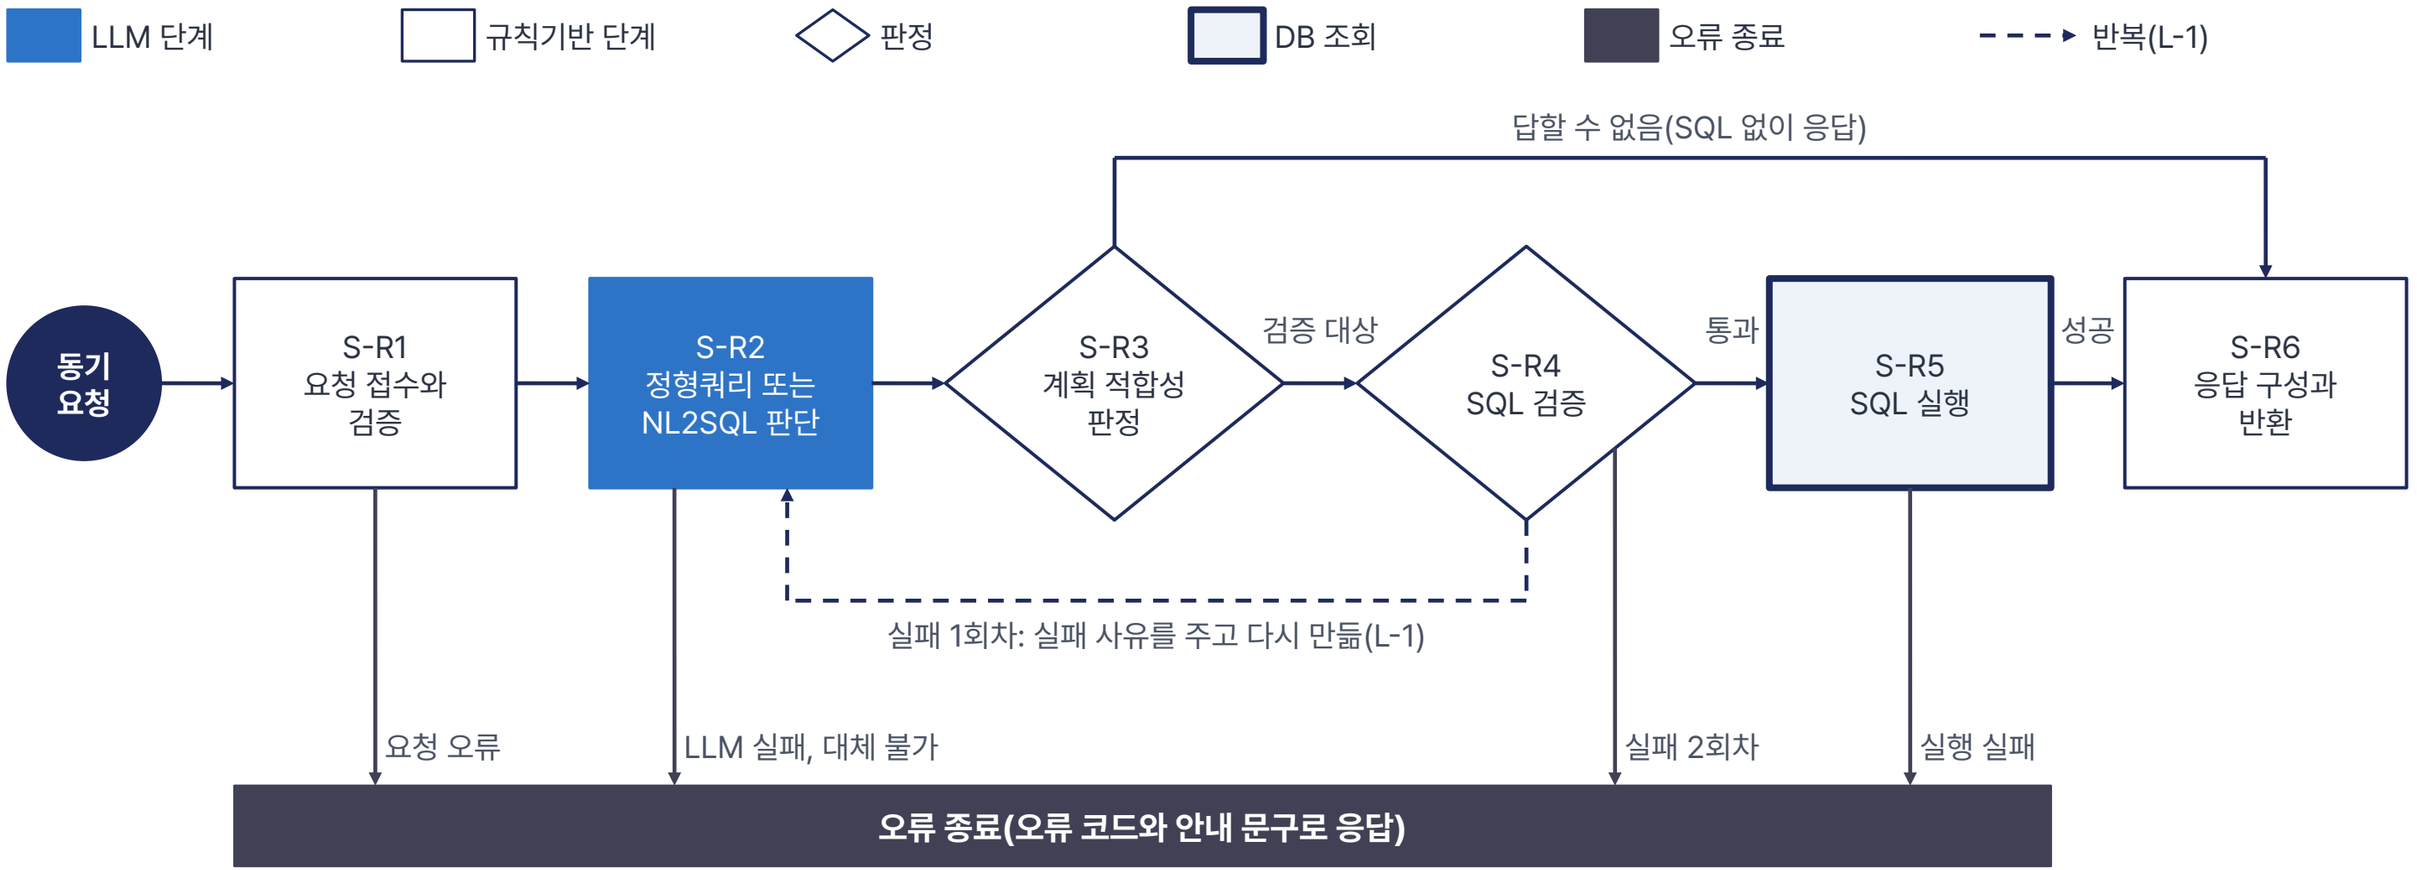
흐름 유형

흐름 유형	위치	판단 이유
순차	S-R1 → S-R2 → S-R3 → S-R4 → S-R5 → S-R6	앞 단계 출력이 뒤 단계 입력임
분기	S-R3	계획이 "답할 수 없음"이면 SQL 없이 S-R6로 감
분기	S-R4	통과는 S-R5, 실패는 다시 만들기 또는 오류 종료
반복	L-1(S-R2 ~ S-R4)	검증 실패 사유를 주고 SQL을 1회 다시 만듦
병렬	없음	모든 단계가 바로 앞 단계 출력을 써서 동시에 돌릴 단계가 없음

무단전재 및 배포 금지

① 단계 도출 및 순서 정의: 흐름 도식

LLM은 경로 판단 한 곳에서만 쓰고, SQL은 검증을 통과해야만 DB로 감



모든 단계는 시작 전에 ⑥ 남은 시간 예산을 확인하고, 기준에 못 미치면 착지 단계로 감

무단전재 및 배포 금지

① 단계 도출 및 순서 정의: Mermaid 도식 스크립트

같은 흐름을 Mermaid 스크립트로도 남겨 누구나 다시 그릴 수 있게 함

```
flowchart LR
    T((동기 요청)) --> R1[S-R1 검색 요청 접수와 검증]
    R1 --> R2[S-R2 정형쿼리 또는 NL2SQL 판단]
    R2 --> R3{S-R3 계획 적합성 판정}
    R3 -- 답할 수 없음 --> R6[S-R6 응답 구성과 반환]
    R3 -- 검증 대상 --> R4{S-R4 SQL 검증}
    R4 -- 통과 --> R5[(S-R5 SQL 실행)]
    R4 -. 실패 1회차 L-1 .-> R2
    R4 -- 실패 2회차 --> E((오류 종료))
    R5 -- 성공 --> R6
    R5 -- 실패 --> E
    R1 -- 요청 오류 --> E
    R2 -- LLM 실패 대체 불가 --> E
```

보는 방법

1. mermaid.live/edit 접속
2. 왼쪽 편집 창에 스크립트 붙여 넣기
3. 오른쪽 위 전체보기 아이콘을 눌러 봄

> ***노드 R1 ~ R6은 단계 S-R1 ~ S-R6, 점선은 반복 구간 L-1임***

무단전재 및 배포 금지

② 단계별 명세: S-R1 검색 요청 접수와 검증

잘못된 요청과 개인 식별자는 첫 단계에서 걸러, 외부 LLM에 가는 글을 최소로 만듦

단계ID	단계명	이전 단계	담당자 유형	외부시스템
S-R1	검색 요청 접수와 검증	트리거(동기 요청)	규칙기반 코드	없음(시스템 내부 DB)

비즈니스 목표	형식이 맞고 실제로 있는 회원의 질문만 받아, 개인 식별자를 가린 질문으로 바꿈

입력 데이터	수행 작업	출력 데이터
request_id(str, 선택, 호출자 추적 ID) member_id(str, 필수, 상담 대상 회원ID) question(str, 필수, 상담사 질문 1 ~ 500자) base_date(date, 선택, 조회 기준일)	1. 필수 값과 형식 확인(member_id는 M- + 숫자 4자리) 2. 읽기 전용 트랜잭션에서 public.lab_metadata의 base_date, txn_period를 읽어 기준일과 거래 제공 시작일 결정 3. 세션 변수 3개 지정 후 app_internal.member_basic으로 회원과 가입일 확인(statement_timeout ≤ 남은 시간 예산) 4. 질문의 회원ID, 카드번호, 전화번호, 주민등록번호, 이메일을 규칙(정규식)으로 가림	request_id(str, 필수, 없으면 생성) member_id(str, 필수, 내부 전용) masked_question(str, 필수, 가린 질문) masked_types(list, 필수, 가린 종류) base_date(date, 필수) coverage_start(date, 필수, 거래 제공 시작일) started_at(float, 필수, 시작 시각) attempt(int, 필수, 1)

예외 처리	비고
형식 오류 → INVALID_REQUEST(400) 회원 없음 또는 기준일에 가입 전 → MEMBER_NOT_FOUND(404) DB 접속 실패 → DB_UNAVAILABLE(503)	회원ID는 LLM에 보내지 않고 세션 변수로만 씀. 이름은 정규식으로 못 가려 위험 항목으로 둠

무단전재 및 배포 금지

② 단계별 명세: S-R2 정형쿼리 또는 NL2SQL 판단

LLM을 한 번만 불러 경로와 SQL 초안을 함께 받고, 실패하면 키워드 규칙으로 대신함

단계ID	단계명	이전 단계	담당자 유형	외부시스템
S-R2	정형쿼리 또는 NL2SQL 판단	S-R1 검색 요청 접수와 검증, S-R4 SQL 검증(검증 실패로 되돌아올 때)	생성형AI + 규칙기반 코드 (대체 경로)	Groq LLM(C-01)
비즈니스 목표	질문에 맞는 조회 방법을 골라, 정형쿼리가 없을 때만 LLM이 SQL을 만들게 함			

입력 데이터	수행 작업	출력 데이터
masked_question(str, 필수, S-R1) base_date, coverage_start(date, 필수, S-R1) attempt(int, 필수, S-R1 또는 S-R4) validation_errors(list, 선택, S-R4) previous_sql(str, 선택, S-R4)	1. 남은 시간 예산 확인 2. 프롬프트 조립(정형쿼리 목록, 허용 뷰와 컬럼, 기간, 검증 실패 사유) 3. C-01 호출(타임아웃 12초, 재시도 0회, JSON 스키마 엄격 모드) 4. 응답이 스키마와 맞는지 확인 5. 호출 실패 시 정형쿼리 키워드 표로 규칙 매칭(대체 경로)	route(str, 필수, fixed 또는 nl2sql 또는 unanswerable) fixed_query_id(str, 선택) generated_sql(str, 선택) used_views(list, 필수) reason(str, 필수, 판단 근거) plan_source(str, 필수, llm 또는 keyword_fallback) attempt(int, 필수)

예외 처리	비고
시간 초과, 429, 5xx, 스키마 불일치 → 키워드 매칭. 일치 없음 → LLM_UNAVAILABLE(503)	LLM에는 가린 질문과 뷰 구조만 보냄. 회원ID와 결과 행은 보내지 않음

무단전재 및 배포 금지

② 단계별 명세: S-R3 계획 적합성 판정

LLM이 낸 계획을 그대로 믿지 않고, 경로와 내용이 서로 맞는지 규칙으로 판정함

단계ID	단계명	이전 단계	담당자 유형	외부시스템
S-R3	계획 적합성 판정	S-R2 정형쿼리 또는 NL2SQL 판단	규칙기반 코드	없음

비즈니스 목표	답할 수 없는 질문은 SQL 없이 돌려보내고, 나머지는 검증할 SQL 한 개로 정리함

입력 데이터	수행 작업	출력 데이터
route, fixed_query_id, generated_sql, used_views, reason, plan_source, attempt(모두 S-R2)	1. 남은 시간 예산 확인 2. route 값 확인 3. fixed: fixed_query_id가 FQ-01 ~ FQ-09에 있으면 그 SQL을 후보로 4. nl2sql: SQL이 비어 있지 않고 used_views가 허용 뷰 안이면 후보로 5. unanswerable: S-R6로 보냄 6. 경로와 값이 어긋나면 plan_issues에 적어 S-R4에서 실패 처리	decision(str, 필수, to_validate 또는 unanswerable) candidate_sql(str, 선택) plan_issues(list, 필수) route(str, 필수) fixed_query_id(str, 선택) unanswerable_reason(str, 선택) attempt(int, 필수)

예외 처리	비고
남은 시간 예산 미달 → BUDGET_EXCEEDED(504)	"답할 수 없음"은 오류가 아니라 정상 응답(status unanswerable)임

무단전재 및 배포 금지

② 단계별 명세: S-R4 SQL 검증

LLM이 만든 SQL은 허용 범위를 검사하기 전에는 절대 실행하지 않음

단계ID	단계명	이전 단계	담당자 유형	외부시스템
S-R4	SQL 검증	S-R3 계획 적합성 판정	규칙기반 코드	없음(시스템 내부 DB)
비즈니스 목표	허용된 뷰와 구문만 쓰는 읽기 SQL만 실행 단계로 넘겨 데이터 유출과 DB 부하를 막음			

입력 데이터	수행 작업	출력 데이터
candidate_sql(str, 선택, S-R3) plan_issues(list, 필수, S-R3) route, fixed_query_id, attempt(S-R3)	1. 남은 시간 예산 확인 2. plan_issues가 있으면 실패 3. 구문 분석으로 SELECT 1문장인지 확인 4. 금지 구문, 주석, 여러 문장 확인 5. 뷰, 컬럼, 함수가 허용 목록 안인지 확인 6. LIMIT을 201(상한 200 + 잘림 확인 1)로 강제 7. 읽기 전용 트랜잭션에서 EXPLAIN으로 문법과 권한 확인	validated_sql(str, 선택) row_limit(int, 필수, 200) validation_errors(list, 필수) previous_sql(str, 선택) attempt(int, 필수, 되돌아갈 때 2) route, fixed_query_id

예외 처리	비고
실패 1회차 → S-R2로 되돌아감(L-1) 실패 2회차 → SQL_VALIDATION_FAILED(422) 오류 종료	실패 사유는 LLM에만 돌려주는 내부 정보. 호출자 오류 메시지에 SQL, 뷰 이름을 넣지 않음

무단전재 및 배포 금지

② 단계별 명세: S-R5 SQL 실행

세션 변수로 회원 범위를 정한 읽기 전용 트랜잭션에서, 남은 시간 안에서만 SQL을 실행함

단계ID	단계명	이전 단계	담당자 유형	외부시스템
S-R5	SQL 실행	S-R4 SQL 검증	규칙기반 코드	없음(시스템 내부 DB)
비즈니스 목표	검증된 SQL을 이 회원의 데이터 범위 안에서만 실행해 답의 근거 데이터를 얻음			

입력 데이터	수행 작업	출력 데이터
validated_sql, row_limit, route, fixed_query_id(S-R4) member_id, base_date, coverage_start(S-R1)	1. 남은 시간 예산 측정 2. sql_retriever_user로 연결 3. BEGIN READ ONLY 4. set_config로 app.member_id, app.base_date, app.coverage_start 지정(트랜잭션 한정) 5. SET LOCAL statement_timeout = min(남은 시간 예산, 5초) 6. SQL 실행, 201행째가 있으면 잘림 표시 7. ROLLBACK으로 끝내 세션 변수 정리	columns(list, 필수, 컬럼명과 타입) rows(list, 필수, 최대 200행) row_count(int, 필수) truncated(bool, 필수) db_elapsed_ms(int, 필수) route, fixed_query_id(전달)

예외 처리	비고
문장 시간 초과(57014) → SQL_TIMEOUT(504) 그 밖의 DB 오류 → SQL_EXECUTION_FAILED(500) 접속 실패 → DB_UNAVAILABLE(503)	0행은 정상 결과. 결과 행은 LLM에 보내지 않음. 문장 상한 5초는 설계 가정

무단전재 및 배포 금지

② 단계별 명세: S-R6 응답 구성과 반환

정상, 답할 수 없음 두 경우를 같은 응답 형식으로 돌려줘 호출자가 한 가지 방식으로 처리함

단계ID	단계명	이전 단계	담당자 유형	외부시스템
S-R6	응답 구성과 반환	S-R5 SQL 실행, S-R3 계획 적합성 판정(답할 수 없음 경로)	규칙기반 코드	없음
비즈니스 목표	결과와 근거(경로, 기간, 잘림 여부)를 한 형식으로 돌려줘 호출자가 답변을 바로 만들게 함			

입력 데이터	수행 작업	출력 데이터
columns, rows, row_count, truncated, route, fixed_query_id(S-R5) decision, unanswerable_reason(S-R3) request_id, base_date, coverage_start, started_at(S-R1)	1. status 결정(ok 또는 unanswerable) 2. 응답 JSON 조립 3. elapsed_ms 계산 4. 감사 로그 기록(가린 질문, 경로, SQL 해시, 행 수, 소요 시간. 회원ID는 해시) 5. 반환	request_id(str) status(str) route(str) fixed_query_id(str, 선택) period(obj, base_date와 coverage_start) columns, rows(list) row_count(int) truncated(bool) message(str) elapsed_ms(int)

예외 처리	비고
조립 실패 → INTERNAL_ERROR(500)	종료 처리 시간 1초 안에서 수행. 응답에 SQL을 넣지 않음

무단전재 및 배포 금지

③ 외부시스템 연동 명세

바깥으로 나가는 연동은 Groq LLM 하나뿐이며, 최악값은 12초임

단계ID	외부시스템	연동 유형	커넥터ID	타임아웃	재시도	최악값	초과 시 처리
S-R2	Groq LLM	LLM	C-01	12초	0	12 × (1 + 0) = 12초	대체 경로로 계속(정형쿼리 키워드 매칭), 일치 없으면 안전 종료

1 부분결과로 계속

해당 안 됨

경로와 SQL이 없으면 낼 결과가 없음

2 대체 경로로 계속

채택

정형쿼리 9개의 키워드 표로 규칙 매칭하면 LLM 없이도 자주 묻는 질문은 답함

3 안전 종료

키워드가 맞지 않을 때만

LLM_UNAVAILABLE(503) "잠시 후 다시 시도해 주세요"

> ***판단 이유: 타임아웃 12초는 최대 출력 5000토큰 ÷ 약 500토큰/초 ≈ 10초에 여유 2초를 더한 설계 가정. 재시도 0회는 다시 만들기(L-1)와 합쳐 30초를 넘지 않게 하려는 사용자 결정***

DB는 시스템 내부 구성요소라 이 표에 넣지 않음

출처: Groq Models, Reasoning 문서(2026-10-15 조사), work/decisions.json D-05

무단전재 및 배포 금지

④ 반복 구간 명세

SQL 검증에 실패하면 실패 사유를 LLM에 주고 한 번만 다시 만듦

반복구간ID	비즈니스 목표	단계ID	재시도	최악값	착지 단계
L-1	검증을 통과할 때까지 SQL을 다시 만듦	S-R2 ~ S-R4	1	(12 + 0 + 0) × (1 + 1) = 24초	안전 종료(SQL_VALIDATION_FAILED 422)

최악값 계산

- S-R2 단계 최악값 12초(C-01 타임아웃 12초 × (1 + 0))
- S-R3, S-R4는 외부 연동 없음 → 0초
- **구간 최악값 = (12 + 0 + 0) × (1 + 1) = 24초**

착지 단계 판단 이유

- 부분결과: 없음(실행할 SQL이 없음)
- 대체 경로(키워드 매칭): LLM이 이미 nl2sql로 판단한 질문이라 맞지 않는 정형쿼리를 고를 위험이 있어 쓰지 않음
- **결론: 안전 종료(SQL_VALIDATION_FAILED 422)**

출처: 설계 가이드 1-4, work/decisions.json D-08

무단전재 및 배포 금지

⑤ 워크플로우 명세

최악값 합계 24초로 전체 시간 예산 30초 안에 들고, 남는 5초는 DB와 규칙 처리 몫임

항목	값
워크플로우ID	W-1
이름	SQL 검색기
비즈니스 목표	상담사가 고객 데이터를 직접 찾지 않고 질문 한 줄로 근거 데이터를 받게 함
전체 시간 예산	30초
종료 처리 시간	1초
최악값 합계	S-R1 0초 + L-1 24초 + S-R5 0초 + S-R6 0초 = 24초 (≤ 30초)
재개 방안	해당없음(조회만 하고 바깥에 반영하는 작업이 없음)

최악값 합계 계산과 예산 대조

- 분기 비교: SQL 실행 경로(S-R3 → S-R4 → S-R5 → S-R6)가 답할 수 없음 경로(S-R3 → S-R6)보다 길어 이 경로를 더함
- 반복 구간 단계(S-R2 ~ S-R4)는 따로 더하지 않고 L-1 24초로 한 번만 더함
- **예산 대조: 24초 ≤ 30초 → 통과. 조정 없음**
- 여유: 30 - 24 - 1(종료 처리) = 5초 → DB 조회(S-R1 회원 확인, S-R4 EXPLAIN, S-R5 실행)와 규칙 처리 몫. 개발 후 실측으로 확인할 항목

출처: 설계 가이드 1-5, work/decisions.json D-02

무단전재 및 배포 금지

커넥터 설계: 커넥터 목록과 LLM 명세

커넥터는 Groq LLM 하나이며, 접속 주소와 설정값은 모두 Groq 공식 문서 조사값임

ID	커넥터명	연동 방식	제공자
C-01	NL2SQL 계획 생성 LLM	LLM	Groq

DB(PostgreSQL cardlab)는 시스템 내부 구성요소로 취급해 커넥터 목록에서 제외함(사용자 결정)

항목 (C-01 LLM)	값
커넥터 ID	C-01
접속	베이스 URL https://api.groq.com/openai/v1, POST /chat/completions, Authorization: Bearer + 환경변수 GROQ_API_KEY
모델	openai/gpt-oss-120b(Production, 컨텍스트 131,072, 최대 출력 65,536)
하이퍼파라미터	temperature 0.1(범위 0 ~ 2) / top_p 1(기본) / reasoning_effort high(low, medium, high) / reasoning_format hidden / max_completion_tokens 5000 / seed 42 / n 1 / stream false
구조화 출력	response_format json_schema, strict true(모든 필드 required, additionalProperties false)
호출 제한	SDK timeout=12, max_retries=0(기본 60초, 2회를 끔). 요청 한도는 확인 필요
실행 설정	제공자와 모델을 환경변수로 1개 선택하는 구조(현재 후보 1개)

출처: console.groq.com/docs (openai, models, api-reference, reasoning, structured-outputs), context7 groq-python, 2026-10-15

무단전재 및 배포 금지

커넥터 설계: 시스템 프롬프트와 유저 프롬프트

시스템 프롬프트는 프롬프트 가이드 8섹션으로 쓰고, 전문은 스크립트 부록에 둠

시스템 프롬프트(섹션별 요약)

섹션	요약
[목표]	질문에 맞는 조회 경로를 고르고, 필요할 때만 허용 뷰로 읽기 SQL 1개를 만듦
[역할]	카드사 상담 데이터에 익숙한 PostgreSQL NL2SQL 전문가
[맥락]	회원 범위와 기간은 DB가 세션 변수로 이미 걸러 둠. SQL에 회원 조건을 쓰지 않음
[입력]	가린 질문, 기준일, 거래 제공 시작일, 정형쿼리 목록, 허용 뷰와 컬럼, 검증 실패 사유
[처리]	정형쿼리 우선 → 없으면 SQL 생성 → 데이터로 답할 수 없으면 unanswerable
[출력]	JSON 5개 필드(route, fixed_query_id, sql, used_views, reason)
[제약조건]	SELECT 1문장, 허용 뷰와 함수만, LIMIT 200 이하, 개인정보 추측 금지
[예시]	질문 3개에 대한 fixed, nl2sql, unanswerable 응답 예

유저 프롬프트 변수

변수	타입	필수	설명
masked_question	str	필수	개인 식별자를 가린 질문
base_date	date	필수	조회 기준일
coverage_start	date	필수	거래 제공 시작일
fixed_query_catalog	list	필수	정형쿼리 ID, 이름, 설명
view_catalog	list	필수	허용 뷰, 컬럼, 타입, 설명
row_limit	int	필수	결과 행 상한 200
validation_feedback	obj	선택	다시 만들 때 실패 사유와 이전 SQL

무단전재 및 배포 금지

커넥터 설계: 응답 데이터 구조

응답은 JSON 스키마 엄격 모드로 받아, 형식이 틀린 답이 다음 단계로 가지 않게 함

C-01 응답 필드

필드	타입	설명
route	string(enum)	fixed, nl2sql, unanswerable 중 하나
fixed_query_id	string 또는 null	fixed일 때 FQ-01 ~ FQ-09, 그 밖에는 null
sql	string 또는 null	nl2sql일 때 SELECT 1문장, 그 밖에는 null
used_views	array(enum)	SQL이나 정형쿼리가 읽는 app 뷰 이름 목록
reason	string	경로를 고른 근거 한 문장(가린 질문 기준)

1. 모든 필드 required, additionalProperties: false(strict 모드 요구 사항)
2. 선택 값은 ["string", "null"] 합 타입으로 표현
3. 스키마가 맞아도 내용 판정은 S-R3, S-R4가 다시 함
4. 응답 메타데이터의 토큰 사용량은 감사 로그에 남김

출처: console.groq.com/docs/structured-outputs (2026-10-15 조사)

무단전재 및 배포 금지

⑥ 남은 시간 예산 정책: 측정과 계산

각 단계 시작 직전에 실제로 흐른 시간을 재고, 남은 시간 예산이 1.5초 이상일 때만 시작함

이름	계산식 또는 값
측정 시점	S-R1 ~ S-R5 각 단계 시작 직전(S-R6는 종료 처리 시간으로 확보)
남은 시간	30 - 기존 사용 시간 - 1
남은 시간 예산	남은 시간 - SUM(앞으로 남은 단계의 외부 연동 최악값)
남은 외부 연동 최악값	S-R2 전: 12초(반복 구간이라도 1회분) / S-R3 이후: 0초
시작 기준 시간	30 × 5% = 1.5초
DB 문장 제한	statement_timeout = min(남은 시간 예산, 5초)

계산 예

예 1 S-R2 2회차 시작
사용 13초 → 남은 시간 30 - 13 - 1 = 16초
남은 시간 예산 16 - 12 = 4초 ≥ 1.5초 → 시작

예 2 S-R2 2회차 시작
사용 16초 → 남은 시간 30 - 16 - 1 = 13초
남은 시간 예산 13 - 12 = 1초 < 1.5초 → 착지(안전 종료)

예 3 S-R5 시작
사용 26초 → 남은 시간 30 - 26 - 1 = 3초
남은 시간 예산 3 - 0 = 3초 ≥ 1.5초 → 시작
statement_timeout = min(3초, 5초) = 3초

출처: 설계 가이드 2-1 ~ 2-3

무단전재 및 배포 금지

⑥ 남은 시간 예산 정책: 기준 미달 시 착지 단계

기준에 못 미치면 부분결과 → 대체 경로 → 안전 종료 순서로 검토해 단계마다 착지 단계를 정함

단계	기준 미달 시 착지 단계	판단 이유
S-R1	안전 종료(BUDGET_EXCEEDED 504)	시작 직후라 실제로는 생기지 않음. 규칙상 같은 처리를 둠
S-R2 1회차	대체 경로(키워드 매칭) → 일치 없으면 안전 종료 (BUDGET_EXCEEDED)	LLM 없이도 자주 묻는 질문은 답할 수 있음
S-R2 2회차	안전 종료(SQL_VALIDATION_FAILED 422)	앞 검증 실패를 그대로 알림. L-1 착지와 같음
S-R3	안전 종료(BUDGET_EXCEEDED)	남은 단계에 DB 실행이 있어 시간 확보가 안 되면 결과를 못 냄
S-R4	안전 종료(BUDGET_EXCEEDED)	검증 없이 실행하는 대체 경로는 원칙상 금지
S-R5	안전 종료(BUDGET_EXCEEDED)	부분결과 없음. 실행 도중 초과는 SQL_TIMEOUT
S-R6	해당없음(종료 처리 시간 1초로 확보)	응답 조립은 항상 수행

무단전재 및 배포 금지

부록 A: 논리 뷰 목록

NL2SQL 실행 계정이 읽을 수 있는 뷰는 9개이며, LLM에는 app 스키마 7개만 보여 줌

뷰	담는 내용	주요 컬럼	LLM 노출
app.customer_profile	회원 가입일과 연령대	join_date, age_band	예
app.customer_cards	기준일 현재 보유 카드, 상품, 연회비	card_ref, product_name, brand, annual_fee	예
app.monthly_usage	최근 6개월 카드별 월 승인 이용	card_ref, month, approved_amount	예
app.customer_delinquency	최근 마감 월 연체 1건	base_month, overdue_amount, overdue_days	예
app.customer_delinquency_history	최근 12개월 연체 이력	base_month, overdue_amount	예
app.customer_daily_usage	최근 90일 일별 승인 이용	usage_date, approved_amount	예
app.merchant_usage	최근 6개월 가맹점과 업종별 이용	merchant_name, category, approved_amount	예
app_internal.customer_cards_full	원본 카드ID 포함 조립용 뷰	card_id, card_ref	아니오(서비스 코드 전용)
app_internal.member_basic	회원 존재와 가입일 확인	member_id, join_date	아니오(S-R1 전용)

권한 요약

- RLS: member, card, card_txn, delinquency 테이블에 회원 격리 정책(app.member_id)
- 세션 변수 3개(app.member_id, app.base_date, app.coverage_start)를 지정하지 않으면 0행(기본 거부)
- 원본 테이블 중 sql_retriever_user가 읽는 것은 public.lab_metadata 하나

출처: rdb/init/04 ~ 06 SQL, work/db_catalog.json(2026-10-15 실측)

무단전재 및 배포 금지

부록 B: 정형쿼리 목록

정형쿼리 9개는 모두 실행 계정 권한으로 EXPLAIN을 통과함(실행하지 않고 계획만 확인)

고정 조회ID	설명	결과 단위	SQL 요지
FQ-01	고객 기본정보	고객 1행	customer_profile 전체
FQ-02	보유 카드 목록	카드 1장당 1행	customer_cards, card_ref 순
FQ-03	카드별 월 이용금액(6개월)	카드와 월 1쌍당 1행	monthly_usage, 월과 카드 순
FQ-04	월별 이용금액 합계(6개월)	월 1개당 1행	monthly_usage를 월로 합계
FQ-05	최근 연체 현황	0행 또는 1행	customer_delinquency 전체
FQ-06	연체 이력(12개월)	월 1개당 1행	customer_delinquency_history, 월 순
FQ-07	일별 이용금액(90일)	날짜 1일당 1행	customer_daily_usage, 날짜 순
FQ-08	업종별 이용금액(6개월)	업종 1개당 1행	merchant_usage를 업종으로 합계
FQ-09	가맹점 이용 상위 10곳	가맹점 1곳당 1행	merchant_usage를 가맹점으로 합계, 상위 10

전체 SQL은 work/fixed_queries.json, 확인 로그는 work/explain_fixed_queries.log

출처: work/explain_fixed_queries.log (sql_retriever_user, 9/9 통과)

무단전재 및 배포 금지

부록 C: SQL 검증 규칙

허용 목록에 있는 것만 통과시키는 방식(기본 거부)으로 SQL을 검사함

허용

- 허용 뷰: app 스키마 뷰 7개와 그 컬럼 전부
- 허용 구문: SELECT 1문장, WITH, WHERE, JOIN(허용 뷰끼리), GROUP BY, HAVING, ORDER BY, LIMIT, CASE
- 허용 함수: sum, count, avg, min, max, date_trunc, to_char, extract, coalesce, round, greatest, least, abs, nullif
- 결과 행 상한: 200(검증 단계에서 LIMIT 201로 강제, 201행째는 잘림 표시에만 씀)

금지

- 쓰기와 정의 구문: INSERT, UPDATE, DELETE, MERGE, CREATE, ALTER, DROP, TRUNCATE, GRANT, REVOKE, COPY, SET, CALL, DO
- 여러 문장(세미콜론), 주석(--, /* */), SELECT INTO, FOR UPDATE
- 스키마: app_internal, public, private, pg_catalog, information_schema
- 함수: set_config, current_setting, pg_sleep, generate_series, 허용 목록 밖의 모든 함수

> ***검증을 통과해도 실행은 읽기 전용 트랜잭션과 RLS 안에서만 함(이중 방어)***

무단전재 및 배포 금지

부록 D: 필드 영문명

호출자와 주고받는 필드 이름을 하나로 고정해 구현과 시험이 같은 이름을 쓰게 함

요청 필드

영문명	한글명	타입
request_id	요청 추적 ID	str
member_id	회원ID	str
question	상담사 질문	str
base_date	조회 기준일	date

응답 필드

영문명	한글명	타입
request_id	요청 추적 ID	str
status	처리 결과(ok, unanswerable, error)	str
route	조회 경로(fixed, nl2sql, none)	str
fixed_query_id	고정 조회ID	str
period	조회 기간(base_date, coverage_start)	obj
columns / rows	컬럼 목록 / 결과 행	list
row_count / truncated	행 수 / 잘림 여부	int / bool
message	안내 문구	str
error	오류(code, message)	obj
elapsed_ms	처리 시간(밀리초)	int

무단전재 및 배포 금지

부록 E: 오류 응답

오류 메시지에는 SQL, DB 식별자, 접속 정보, 키를 넣지 않고 다음 행동만 안내함

오류 코드	HTTP 상태	발생 단계	의미	호출자에게 돌려줄 메시지
INVALID_REQUEST	400	S-R1	필수 값 누락 또는 형식 오류	요청 값을 확인해 주세요
MEMBER_NOT_FOUND	404	S-R1	회원이 없거나 기준일에 가입 전	조회할 수 있는 회원이 아닙니다
LLM_UNAVAILABLE	503	S-R2	LLM 실패 + 키워드 매칭 실패	잠시 후 다시 시도해 주세요
SQL_VALIDATION_FAILED	422	S-R4	다시 만들기 후에도 검증 실패	질문을 더 구체적으로 바꿔 주세요
SQL_TIMEOUT	504	S-R5	실행 제한 시간 초과	조회 범위를 줄여 다시 시도해 주세요
SQL_EXECUTION_FAILED	500	S-R5	그 밖의 실행 오류	조회 중 문제가 생겼습니다
DB_UNAVAILABLE	503	S-R1, S-R4, S-R5	DB 접속 실패	잠시 후 다시 시도해 주세요
BUDGET_EXCEEDED	504	S-R1 ~ S-R5	남은 시간 예산 미달	응답 시간이 초과되었습니다
INTERNAL_ERROR	500	모든 단계	예상하지 못한 오류	처리 중 문제가 생겼습니다

오류 응답 형식: request_id, status(error), error(code, message), elapsed_ms

무단전재 및 배포 금지

부록 F: 설계 점검표

설계 가이드 5절 점검표와 이 설계서의 완료 기준을 모두 확인함

점검 항목	결과
단계ID 접두어가 트리거 유형(S-R)과 맞음	통과
입력 필드의 출처 단계가 그 필드를 실제로 출력함	통과(verify_calc.py)
외부시스템이 있는 단계는 ③에 행이 있음(S-R2 → C-01)	통과
③의 커넥터ID가 커넥터 목록에 있음	통과
연동 최악값 = 타임아웃 × (1 + 재시도)	통과(12초)
초과 시 처리와 착지 단계를 부분결과 → 대체 경로 → 안전 종료로 검토함	통과
반복 구간 최악값 = 구간 합계 × (1 + 재시도)	통과(24초)
최악값 합계에서 분기는 가장 큰 경로만 더함	통과
최악값 합계 ≤ 전체 시간 예산	통과(24초 ≤ 30초)
재개 방안이 해당없음 또는 단계별 결과 저장임	통과(해당없음)
LLM 커넥터 필수 항목과 시스템 프롬프트 섹션 구조	통과
이전 단계, 흐름 도식, Mermaid 연결이 서로 같음	통과(verify_calc.py)

무단전재 및 배포 금지

부록 G: 설계 가정과 위험 항목

근거 없는 수치는 설계 가정으로 두고, 개발 후 실측으로 확인함

설계 가정(실측 항목)

1. LLM 타임아웃 12초(최대 출력 5000토큰을 약 500토큰/초로 나눈 값 + 여유)
2. DB 문장 상한 5초, DB와 규칙 처리 몫 5초(30 - 24 - 1)
3. 시작 기준 비율 5%(1.5초)
4. 회원ID 형식 M- + 숫자 4자리, txn_period 값에서 시작일을 꺼내는 방식
5. temperature 0.1에서 반복 출력이 없는지(Groq 권장 0.5 ~ 0.7)
6. Groq 요청 한도(문서끼리 값이 달라 조직 한도 페이지 확인 필요)

위험 항목

1. DB 구조 읽기를 관리자 계정 cardlab으로 함(사용자 결정). 읽기 전용 세션, LIMIT 0과 EXPLAIN만 사용
2. 원본 테이블 읽기: sql_retriever_user는 public.lab_metadata만 읽음(위험 낮음). cardlab은 전부 읽음
3. app_internal 뷰 2개도 실행 계정이 읽을 수 있음 → SQL 검증에서 스키마 금지로 막음
4. 이름 같은 개인 식별자는 정규식으로 못 가림 → 외부 LLM 전송 위험
5. customer_daily_usage의 EXPLAIN 예상 비용이 큼 → 실행 시간 실측 필요

무단전재 및 배포 금지